基于大模型的学术论文结构自动解析方法研究

张伟，李静，王浩然，陈思远

北方理工大学　计算机科学与技术学院，北京　１０００８４

摘要：学术论文的自动化解析是构建科技文献知识库的关键环节。针对现有方法在长文档、多栏排版与复杂标题层级上准确率不足的问题，本文提出一种基于大模型的学术论文结构自动解析方法。该方法首先利用版面分析模型定位标题、正文、图表与参考文献等区域，然后将区域序列输入大语言模型，通过层次化提示学习完成章节标题识别与层级归并，最后结合规则后处理修正编号不一致与跨栏断行带来的错误。在自建的　１２００　篇中英文论文数据集上，本文方法的章节边界识别　Ｆ１　值达到　９４．７％，标题层级判定准确率达到　９１．２％，分别比基线方法提升　５．３　与　６．８　个百分点。实验表明，引入大模型的语义先验能够显著缓解纯规则方法在标题样式多变时的脆弱性，同时保持可接受的计算开销。

关键词：大语言模型；学术论文解析；标题层级识别；版面分析；文档结构抽取

１　引言

随着科技文献数量的快速增长，科研人员难以及时获取论文内部的完整结构信息。通用搜索引擎与文献数据库通常只索引标题、作者与摘要，而论文的章节组织、方法描述与实验结果等结构化信息往往以　ＰＤＦ　版面形式存在，难以被机器直接利用。因此，如何从　ＰＤＦ　文档中自动恢复出符合语义的章节树，成为构建科技知识图谱与智能问答系统的前提条件。

早期研究主要依赖规则与样式特征，例如通过字号、字体、加粗与缩进来判断标题层级。这类方法在排版规范的论文上表现良好，但面对跨出版社模板、双栏混排、扫描件以及图表标题干扰时鲁棒性明显不足。近年来，基于深度学习的版面分析模型能够较准确地检测文本区域及其类别，然而区域类别并不等于章节层级，如何把区域序列映射为带编号的层级结构仍是一个开放问题。

本文的主要贡献包括三点：其一，提出一种区域序列到章节树的端到端解析框架，把标题识别与层级归并统一在一个生成式模型中；其二，设计层次化提示模板，显式引入编号模式与上下文窗口，缓解长文档中上下文缺失的问题；其三，构建了包含　１２００　篇中英文论文的评测数据集，并给出细粒度的评测指标与错误分析。

２　相关工作

文档版面分析。基于目标检测的版面分析模型把页面视为图像，输出文本块、表格、图片与公式等区域及其坐标。此类方法对扫描件效果良好，但通常不区分一级标题与二级标题，需要额外的层级判定模块。

标题层级识别。已有工作利用编号正则表达式与字体统计特征进行层级推断，并借助条件随机场或图神经网络建模相邻标题之间的关系。这类方法依赖于编号书写规范，当作者使用无编号标题或编号跳号时错误率显著上升。

大模型在文档理解中的应用。大语言模型在长文本摘要、信息抽取与结构化生成任务上展现出较强的语义理解能力。部分研究将其用于参考文献解析与表格抽取，但在章节树恢复任务上仍缺乏系统性的评估。

３　方法

本文方法由版面分析、区域序列编码与层次化生成三个模块组成。给定一篇　ＰＤＦ　文档，系统首先逐页解析出文本区域及其版面属性，随后按阅读顺序拼接为区域序列，最后通过大模型生成章节标题及其层

级编号。

３．１　版面分析

我们采用轻量检测网络对页面进行区域划分，输出正文、标题、图表标题、页眉页脚与参考文献五类区域。为处理双栏排版，算法首先依据文本块的水平投影确定栏边界，再在每一栏内部按纵坐标排序，从而得到符合人类阅读习惯的区域顺序。页眉页脚区域通过跨页重复检测剔除，即统计同一文本在文档中的出现频次与出现位置，若某文本在超过　８０％　的页面中出现在页面上下边缘　８％　的区域内，则判定为样板文本。

３．２　层次化提示学习

给定区域序列，我们构造包含三个部分的提示：任务说明、编号模式示例与当前文档的候选标题列表。模型需要为每个候选标题输出层级编号与置信度。为了处理超出上下文窗口的长文档，我们采用滑窗切分并在窗口之间传递已确定的层级状态，保证跨窗口的编号连续性。

３．３　规则后处理

模型输出可能存在编号跳号、层级倒挂与重复标题等问题。我们设计了三类后处理规则：对编号跳号采用最近邻插值补齐；对层级倒挂依照上下文最大层级进行裁剪；对重复标题依据文本相似度与位置距离进行合并。后处理不改变模型的主要判断，但可以消除约　３０％　的格式类错误。

４　实验结果与分析

４．１　实验设置

数据集包含　８００　篇中文论文与　４００　篇英文论文，覆盖计算机、物理与医学三个学科，每篇论文的章节树均由两名标注人员独立标注并交叉校验。评价指标为章节边界识别的精确率、召回率与　Ｆ１　值，以及标题层级判定的准确率。基线方法包括纯规则方法、版面分析加启发式层级判定，以及未使用层次化提示的通用大模型方法。

４．２　主要结果

如表　１　所示，本文方法在全部指标上均优于基线。相比纯规则方法，Ｆ１　值提升５．３　个百分点，层级判定准确率提升　６．８　个百分点；相比未使用层次化提示的大模型方法，Ｆ１　值仍有　２．６　个百分点的提升，说明提示设计对结构化解构任务具有实质影响。

表 1 不同方法在自建数据集上的性能对比

方法	精确率 / %	召回率 / %	F1 / %	层级准确率 / %	耗时 / s
纯规则方法	86.4	84.1	85.2	79.5	3.2
版面分析 + 启发式	89.7	87.9	88.8	84.4	12.6
通用大模型	91.2	90.6	90.9	88.3	48.7
本文方法	95.1	94.3	94.7	91.2	36.4
本文方法（无后处理）	93.8	92.5	93.1	89.0	35.1

4.3 消融实验

为验证各模块的作用，我们分别移除跨页样板检测、层次化提示与规则后处理。移除跨页样板检测后，页眉页脚被误判为标题，导致精确率下降 3.1 个百分点；移除层次化提示后，层级判定准确率下降 4.7 个百分点；移除规则后处理主要影响编号跳号样本，召回率下降 1.8 个百分点。

4.4 错误分析

我们对 120 个失败样本进行了人工分析。其中 42% 的错误来自图表标题被误判为章节标题，主要集中在图表标题采用与正文相同字号的模板；27% 来自扫描件中文本区域检测不完整；19% 来自作者使用了非标准的自定义编号体系；其余错误与多语言混排有关。这些观察为后续改进指明了方向。

5 结论与展望

本文提出了一种基于大模型的学术论文结构自动解析方法，通过区域序列建模、层次化提示学习与规则后处理，在自建数据集上取得了 94.7% 的 F1 值与 91.2% 的层级判定准确率。实验表明，语义先验与结构约束的结合能够有效提升解析鲁棒性。未来工作将从三个方向展开：一是引入视觉信息以处理扫描件与复杂公式；二是扩展到跨语言与跨学科场景，构建统一的结构解析模型；三是研究在线增量解析，支持论文预印本的实时结构化入库。

参考文献

[1] 王浩然，张伟．面向科技文献的版面分析方法综述[J]．计算机学报，2024，47(3)：512-530．

[2] 李静，陈思远．基于预训练语言模型的文档结构抽取[J]．软件学报，2023，34(11)：4901-4918．

[3] 赵敏，刘洋．长文档层次化建模研究进展[J]．自动化学报，2025，51(2)：233-249．

[4] 孙鹏，周颖．中文 PDF 文档阅读顺序恢复方法[J]．中文信息学报，2024，38(6)：78-89．

[5] Xu Y, Li Z, Zhang H, et al. A benchmark for document layout analysis in scientific papers[C]. Proceedings of ICDAR, 2023: 220-235.

[6] Chen L, Wang R, Sun Q. Hierarchical structure recovery from scholarly PDFs with large language models[C]. Proceedings of ACL, 2024: 1188-1201.

[7] Brown T, Mann B, Ryder N, et al. Language models are few-shot learners[C]. Advances in Neural Information Processing Systems, 2020:

1877-1901.

[8] Zhang Y, Liu M, Chen X. Cross-page boilerplate detection for web-scale document parsing[J]. Information Processing and Management, 2024, 61(4): 103-119.